

Sparse PEFT 论文中的重要性指标整理

2026 年 5 月 14 日

1 阅读范围与筛选口径

当前目录共有 23 篇 PDF。本文只保留稀疏/选择性 PEFT 或与其直接同类的论文；以下 16 篇纳入：

1. Parameter-efficient transfer learning with diff pruning
2. Masking as an efficient alternative to finetuning for pretrained language models
3. Composable Sparse Fine-Tuning for Cross-Lingual Transfer
4. Raise a Child in Large Language Model: Towards Effective and Generalizable Fine-tuning
5. Random Masking Finds Winning Tickets for Parameter Efficient Fine-tuning
6. Parameter-Efficient Sparsity for Large Language Models Fine-Tuning
7. Sparse is Enough in Fine-tuning Pre-trained Large Language Models
8. Scaling Sparse Fine-Tuning to Large Language Models
9. SMT: Fine-Tuning Large Language Models with Sparse Matrices
10. GaLLoP: Gradient-based Sparse Learning on Low-Magnitude Parameters
11. SAFT: Towards Out-of-Distribution Generalization in Fine-Tuning
12. Sensitivity-Aware Visual Parameter-Efficient Fine-Tuning
13. Unified Low-Resource Sequence Labeling by Sample-Aware Dynamic Sparse Finetuning
14. Continual Learning via Sparse Memory Finetuning
15. Rapid Switching and Multi-Adapter Fusion via Sparse High Rank Adapters
16. SparseLoRA: Accelerating LLM Fine-Tuning with Contextual Sparsity

以下 7 篇不纳入主表：AWQ（量化）、BitFit（固定 bias 调参，不是稀疏选择）、Neural architecture search for PEFT（结构搜索而非稀疏选择）、Dynamic Network Surgery、Rigging the Lottery、The Lottery Ticket Hypothesis、Training Neural Networks with Fixed Sparse Masks（后四者是通用稀疏训练/剪枝背景，不是 PEFT）。

2 统一记号

- 数据集: $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- 预训练参数: $\theta \in \mathbb{R}^D$
- 第 i 个参数: θ_i
- 单样本损失: $\ell(x_i, y_i; \theta)$
- 经验损失: $\mathcal{L}_{\mathcal{D}}(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(x_i, y_i; \theta)$
- 参数梯度: $g = \nabla_{\theta} \mathcal{L}_{\mathcal{D}}(\theta)$, 第 i 维为 g_i
- 若在单层矩阵上讨论参数, 则用 W 表示该层权重矩阵, 用 $G = \nabla_W \mathcal{L}_{\mathcal{D}}(\theta)$ 表示其梯度
- 二值选择掩码: $m \in \{0, 1\}^D$
- 选择算子: $\text{TopK}(s, K)$ 表示取得分 s 最大的 K 个位置
- 若论文按矩阵、子矩阵或通道选择, 下文会显式写出对应索引

文中“论文原式”表示论文直接给出或可直接对应到原文公式; “形式化重写”表示论文只用文字描述, 我把它改写成严格符号形式, 语义与原文一致。

3 一页总表

论文	选择对象	指标/分数	是否依赖额外稠密筛选
Diff Pruning	参数差分 δ	学习到的门控分数 + 末端 $ \delta_i $	否 (与训练联动)
Masking	参数级 mask	学习到的实值 mask $m_{l,ij}$	否 (与训练联动)
LT-SFT	参数	$ \theta_i^{(1)} - \theta_i^{(0)} $	是
Child-Tuning-D	参数	empirical Fisher 对角元	是
Child-Tuning-F	参数	无; 随机 Bernoulli	否
Random Masking	参数	无; 随机 Bernoulli	否
PST	参数	$ W^{(0)} + \beta UV + \alpha_1 AB + \alpha_2 (R + C)$	部分
SIFT	参数	$ g_i $ 的 top- $x\%$	是
SpIEL	参数	drop 用 $ \phi - \phi_0 $; grow 用累计梯度或 SM3 动量近似	周期性稠密梯度
SMT	子矩阵	warm-up 梯度累计后子矩阵均值	是
GalLoP	参数	$ g_i /(\theta_i + \varepsilon)$	是
SAFT	参数	数据集平均梯度的绝对值	是
SPT	参数/矩阵	敏感度 $s_n \approx g_n^2$	是
FISH-DIP	参数	top- n hardest samples 上的 empirical Fisher	是, 且周期性
Sparse Memory FT	memory slot	TF-IDF(memory access)	否

论文	选择对象	指标/分数	是否依赖额外稠密筛选
SHiRA	参数	WM / Grad / SNIP / Rand / Struct	视 mask 构造而定
SparseLoRA	通道	L2-activation 或 $q \odot k$	否（激活驱动）

4 逐篇整理

4.1 学习型 mask / score

Diff Pruning. 核心对象是任务差分向量 δ_τ , 其中

$$\theta_\tau = \theta + \delta_\tau, \quad \delta_\tau = z_\tau \odot v_\tau.$$

训练期把 z_τ 放松为 hard-concrete 随机门控; 若记其参数为 $\alpha_{\tau,i}$, 则可把

$$s_i^{\text{gate}} := \sigma\left(\alpha_{\tau,i} - \log \frac{-l}{r}\right)$$

视为第 i 个位置的可学习重要性分数, 因为论文直接给出

$$\mathbb{E}\|\delta_\tau\|_0 = \sum_{i=1}^D \sigma\left(\alpha_{\tau,i} - \log \frac{-l}{r}\right).$$

训练后再投影到 L_0 -ball, 保留 δ_τ 中绝对值最大的 $t\%$ 分量:

$$s_i^{\text{proj}} := |\delta_{\tau,i}|, \quad m_i = \mathbf{1}\left[s_i^{\text{proj}} \in \text{TopK}(s^{\text{proj}}, \lfloor tD \rfloor)\right].$$

这是“学习 score + 末端 magnitude 投影”的两阶段方案。来源: Diff Pruning, 第 3.1 节与第 3.2 节。

Masking as an Efficient Alternative to Finetuning. 对每层线性权重 W_l , 论文引入同形状实值 mask M_l , 并经阈值化得到二值 mask:

$$(m_l^{\text{bin}})_{ij} = \begin{cases} 1, & m_{l,ij} \geq \tau, \\ 0, & m_{l,ij} < \tau. \end{cases}$$

因此其重要性指标就是训练出的实值 mask 本身:

$$s_{ij}^{(l)} := m_{l,ij}.$$

被保留的参数满足

$$(i, j) \in \mathcal{S}_l \iff s_{ij}^{(l)} \geq \tau.$$

训练时通过 straight-through estimator 更新

$$M_l \leftarrow M_l - \eta \frac{\partial \mathcal{L}(\widehat{W})}{\partial M_l^{\text{bin}}}, \quad \widehat{W}_l = W_l \odot M_l^{\text{bin}}.$$

这里“重要性分数”本身就是可学习变量。来源: 该文第 3.2 节, Eq. (1)–(2)。

4.2 先全量得到信号，再选稀疏子集

Composable Sparse Fine-Tuning / LT-SFT. 论文分两阶段：先从预训练参数 $\theta^{(0)}$ 出发做一次全量微调得到 $\theta^{(1)}$ ，再按参数改变量绝对值排序，选 top- K 个位置：

$$s_i := \left| \theta_i^{(1)} - \theta_i^{(0)} \right|, \quad \mu_i = \mathbf{1}[s_i \in \text{TopK}(s, K)].$$

第二阶段只更新 $\mu_i = 1$ 的位置。这是典型的先全量微调，再用 movement / diff 选 sparse support。来源：第 3.1 节。

Child-Tuning-D. 论文给出 Fisher Information Matrix

$$F(\theta) = \mathbb{E} \left[\left(\frac{\partial \log p(y | x; \theta)}{\partial \theta} \right) \left(\frac{\partial \log p(y | x; \theta)}{\partial \theta} \right)^\top \right].$$

实际使用 empirical Fisher 对角元作为参数重要性。对第 i 个参数：

$$F^{(i)}(\theta) = \frac{1}{N} \sum_{j=1}^N \left(\frac{\partial \log p(y_j | x_j; \theta)}{\partial \theta_i} \right)^2.$$

于是

$$s_i := F^{(i)}(\theta), \quad m_i = \mathbf{1}[s_i \in \text{TopK}(s, \lfloor p_D D \rfloor)].$$

来源：第 2.3 节，Eq. (10)。

PST. 对单层权重矩阵 $W \in \mathbb{R}^{n \times k}$ ，论文先给出通用选择框架

$$M_{ij} = f(S, v)_{ij} = \begin{cases} 1, & S_{ij} \in \text{top-}v, \\ 0, & \text{otherwise.} \end{cases}$$

其提出的 PST 分数为

$$S^{(t)} = \left| W^{(0)} + \beta U^{(t)} V^{(t)} \right| + \alpha_1 A^{(t)} B^{(t)} + \alpha_2 (R^{(t)} + C^{(t)}).$$

其中第一项是 data-free magnitude 项， AB 是低秩 data-driven 项， $R + C$ 是结构化行/列重要性项。论文把行、列结构项写为

$$R^{(t)} = - \sum_{i=0}^t \sum_{j=0}^k \left[\left(\frac{\partial \mathcal{L}^{(i)}}{\partial W} \right) W^{(i)} \right]_{:,j},$$

$$C^{(t)} = - \sum_{i=0}^t \sum_{j=0}^n \left[\left(\frac{\partial \mathcal{L}^{(i)}}{\partial W} \right) W^{(i)} \right]_{j,:}.$$

最后按 $S^{(t)}$ 取 top- v 。来源：第 3.1 节 Eq. (1)–(3)，第 3.2 节 Eq. (4)–(8)。

SIFT. 对某一步梯度 g_k , 取绝对值最大的 top- $x\%$ 分量。若排序后索引满足

$$|g_k^{i_1}| \geq |g_k^{i_2}| \geq \dots \geq |g_k^{i_m}|, \quad m = \lfloor x\% \cdot n \rfloor,$$

则被更新的子空间为

$$\mathcal{S} = \text{span}\{e_{i_1}, e_{i_2}, \dots, e_{i_m}\}.$$

因此指标可写成

$$s_i := |g_{k,i}|, \quad m_i = \mathbf{1}[s_i \in \text{TopK}(s, m)].$$

实现上通常用第一批或前几批累计梯度来固定这组索引。来源：第 4.1 节。

SMT. SMT 选择的是子矩阵而不是单个参数。把某个权重矩阵分块为若干 $l \times l$ 子矩阵 $B_1, \dots, B_N$ 。warm-up 阶段累计梯度后, 对每个子矩阵计算平均绝对梯度分数:

$$G_{uv} := \sum_{t=1}^{T_w} \nabla W_{uv}^{(t)}, \quad s_b := \frac{1}{|B_b|} \sum_{(u,v) \in B_b} |G_{uv}|.$$

再选 top- $z\%$ 子矩阵:

$$m_b = \mathbf{1}[s_b \in \text{TopK}(s, \lfloor zN \rfloor)].$$

论文也讨论 activation-aware selection, 但最终主方法用的是 gradient-aware selection。来源：第 3 节。

GalLoP. 设用于打分的数据子集为 $\mathcal{D}_s = \{(x_i, y_i)\}_{i=1}^{N_s}$ 。论文先在该子集上计算平均梯度

$$g = \frac{1}{N_s} \sum_{i=1}^{N_s} \nabla_{\theta} \ell(x_i, y_i; \theta),$$

再定义分数

$$s = \frac{|g|}{|\theta| + \varepsilon}, \quad s_i = \frac{|g_i|}{|\theta_i| + \varepsilon}.$$

然后按 top- $\rho\%$ 选取:

$$m_i = \begin{cases} 1, & s_i \geq s_t, \\ 0, & s_i < s_t, \end{cases} \quad s_t = \text{sorted}_{\downarrow}(s)[\lfloor \rho D \rfloor].$$

这是一个典型的“高梯度 + 低预训练模长”比值指标。来源：第 4 节 Eq. (1)–(4)。

SAFT. SAFT 在整个下游数据集上平均交叉熵梯度。为避免和参数记号冲突, 把该平均梯度向量记为 $\bar{g}$:

$$\bar{g} = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \ell(x_i, y_i; \theta).$$

于是参数重要性为

$$s_i := |\bar{g}_i|.$$

给定稀疏率 α , 令 $d = \lfloor \alpha D \rfloor$, 则掩码为

$$m_k = \begin{cases} 1, & |\bar{g}_k| \geq \text{sorted}_{\downarrow}(|\bar{g}|)[d], \\ 0, & \text{otherwise.} \end{cases}$$

论文强调它不是先平方再平均的 Fisher 对角, 而是先平均梯度再取绝对值。来源: 第 2.2 节 Eq. (2)–(3) 与 Algorithm 1。

SPT. SPT 从“参数敏感度”出发。先定义第 n 个参数的理想敏感度

$$s_n = \mathcal{L}_{\mathcal{D}_t}(\theta) - \mathcal{L}_{\mathcal{D}_t}(\theta \mid \theta_n = \theta_n^*),$$

其中 θ_n^* 是单独调整第 n 个参数后的最优值。再用一阶 Taylor 展开与 one-step unroll 得到

$$s_n^{(1)} = -g_n \Delta \theta_n, \quad \Delta \theta_n \approx -\eta g_n,$$

从而

$$s_n^{(1)} \approx \eta g_n^2.$$

比较大小时可忽略公共因子 η , 因此实际指标就是

$$s_n \propto g_n^2.$$

随后取 top- τ 敏感参数形成集合 $\mathcal{T}$ 。对某个矩阵 W 的元素 W^j 定义

$$M^j = \begin{cases} 1, & W^j \in \mathcal{T}, \\ 0, & W^j \notin \mathcal{T}. \end{cases}$$

若某一权重矩阵内被选中的敏感参数数目超过阈值 σ_{opt} , 则从 unstructured tuning 切换到 structured tuning:

$$W' = \begin{cases} W + W_{\text{down}} W_{\text{up}}, & \sum_j M^j \geq \sigma_{\text{opt}}, \\ W - \eta G \odot M, & \sum_j M^j < \sigma_{\text{opt}}. \end{cases}$$

来源: 第 3.1 节 Eq. (1)–(3), 第 3.2 节 Eq. (4)–(5)。

FISH-DIP. 静态 FISH mask 用 empirical Fisher:

$$\hat{F}_{\theta} \approx \frac{1}{N} \sum_{i=1}^N (\nabla_{\theta} \log p_{\theta}(y_i \mid x_i))^2.$$

FISH-DIP 的创新是只用当前最退化、最难的 top- n 样本集合 $\mathcal{H}_t$ 周期性重算:

$$\hat{F}_{\theta} \approx \frac{1}{n} \sum_{(x_i, y_i) \in \mathcal{H}_t} (\nabla_{\theta} \log p_{\theta}(y_i \mid x_i))^2.$$

然后每隔 m 步重新排序, 取 top- $k\%$ 参数:

$$m_i = \mathbf{1} \left[\hat{F}_{\theta, i} \in \text{TopK}(\hat{F}_{\theta}, \lfloor k\% \cdot D \rfloor) \right].$$

来源: 第 2.2 节 Eq. (1), 第 2.3 节 Eq. (2), Algorithm 1。

4.3 动态 sparse support / 迭代 drop-grow

SpIEL-AG / SpIEL-MA. SpIEL 的活动索引集合 $\mathcal{I}^{(i)}$ 会动态变化。对第 i 个参数子向量, 当前稀疏增量为 $\phi^{(i)}$, 旧值为 $\phi_0^{(i)}$ 。

drop 指标: 删去与预训练值相比变化最小的位置

$$\mathcal{I}_{\text{drop}}^{(i)} = \text{argtopk}_{k(i,t)} \left(-|\phi^{(i)} - \phi_0^{(i)}| \right).$$

SpIEL-AG 的 grow 指标: 用最近 γ 步平均梯度绝对值

$$\hat{g}_j^{(i)}(t) = \frac{1}{\gamma} \sum_{s=t-\gamma+1}^t \frac{\partial \ell(x_s, y_s; \theta')}{\partial \theta_j^{(i)}},$$

再选 top- $k(i, t)$:

$$\mathcal{I}_{\text{grow}}^{(i)} = \text{argtopk}_{k(i,t)} \left(|\hat{g}^{(i)}(t)| \right).$$

SpIEL-MA 的 grow 指标: 用 SM3 的行列累积量构造动量近似。若参数矩阵为 $r \times c$, SM3 维护行统计 r_i 与列统计 c_j , 则

$$|\hat{m}_{ij}| = \sqrt[4]{r_i c_j}.$$

按 $|\hat{m}_{ij}|$ 取 top- k 生长。来源: SpIEL 第 3.2 节 Eq. (7)–(8)、Algorithm 1; 第 3.3 节 Eq. (9)、Algorithm 2。

4.4 非梯度型 / 异质信号

Sparse Memory Finetuning. 这篇论文不是在普通权重上筛选, 而是在 memory slots 上筛选。对一个 batch 内 memory slot i 的访问次数 $c(i)$, 以及背景 batch 集合 B 中的计数 $c_b(i)$, 定义

$$\text{TFIDF}(i) = \frac{c(i)}{\sum_{j \in M} c(j)} \cdot \log \frac{|B| + 1}{\sum_{b \in B} \mathbf{1}_{c_b(i) > 0} + 1}.$$

然后选 top- t 个 slot:

$$m_i = \mathbf{1}[\text{TFIDF}(i) \in \text{TopK}(\text{TFIDF}, t)].$$

这是最典型的非梯度型指标之一。来源: 第 4 节。

SHiRA. SHiRA 定义稀疏 mask $M \in \{0, 1\}^{n \times m}$, 通过梯度屏蔽仅更新少量预训练权重。论文给出五种 mask 构造方式。对层内参数索引集合 Ω , 令选择数量为 K 。

1. SHiRA-Rand:

$$s_{ij}^{\text{Rand}} \sim \text{Ber}(p), \quad m_{ij} = s_{ij}^{\text{Rand}}.$$

2. SHiRA-WM:

$$s_{ij}^{\text{WM}} := |W_{ij}|, \quad m_{ij} = \mathbf{1}[s_{ij}^{\text{WM}} \in \text{TopK}(s^{\text{WM}}, K)].$$

3. SHiRA-Grad:

$$s_{ij}^{\text{Grad}} := |g_{ij}^{\text{cal}}|, \quad m_{ij} = \mathbf{1}[s_{ij}^{\text{Grad}} \in \text{TopK}(s^{\text{Grad}}, K)].$$

4. SHiRA-SNIP:

$$s_{ij}^{\text{SNIP}} := |W_{ij} g_{ij}^{\text{cal}}|.$$

5. SHiRA-Struct: 不是数据驱动分数, 而是预定义结构的行、列加对角线可训练。

来源: 第 3.1 节 mask strategies 列表。

SparseLoRA. SparseLoRA 不是选择“哪些参数可训练”, 而是选择当前输入下哪些通道需要参与计算。为避免与参数维度 D 冲突, 这里把层内通道维度记为 H 。

对 FFN / VO 投影, 若某层输入激活展平后为 $A \in \mathbb{R}^{(BL) \times H}$, 第 c 个通道的重要性定义为

$$s_c^{\text{L2}} := \|A_{:,c}\|_2.$$

对 QK 投影, 若 query / key 为 $Q, K \in \mathbb{R}^{(BL) \times H}$, 先计算逐通道范数

$$q_c := \|Q_{:,c}\|_2, \quad k_c := \|K_{:,c}\|_2,$$

再定义

$$s_c^{\text{QK}} := q_c k_c.$$

论文还用离线 SVD 近似 oracle activation。若

$$W \approx W_A W_B,$$

则可在该 proxy 上计算同样的激活型指标。来源: 第 3.1.1 节, 第 3.1.2 节, 第 3.2 节。

4.5 无显式重要性指标, 但需要记录

Child-Tuning-F. 直接随机保留梯度:

$$M_t \sim \text{Ber}(p_F).$$

它没有显式 importance score, 只是随机掩码基线。来源: 第 2.2 节。

Random Masking. 对每个参数张量 W^i 采样固定随机 mask:

$$M_{ab}^i \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p).$$

对应优化变量是稀疏矩阵 S^i , 但没有任何 importance score。来源: 该文第 2 节附近对 $\text{Ber}(p)$ 的描述。

5 值得抽象出来的指标家族

从这 16 篇里, 可以把指标大致归成 8 类:

1. 梯度幅值类: $s_i = |g_i|$ 。代表: SIFT、SAFT、SMT、SHiRA-Grad。
2. Fisher / 平方梯度类: $s_i = g_i^2$ 或 $s_i = \mathbb{E}[g_i^2]$ 。代表: Child-Tuning-D、SPT、FISH-DIP。
3. movement / 参数变化类: $s_i = |\theta_i^{(1)} - \theta_i^{(0)}|$ 或 $s_i = |\delta_i|$ 。代表: LT-SFT、Diff Pruning。
4. 梯度-参数联合类: $s_i = |g_i|/(|\theta_i| + \varepsilon)$ 或 $s_i = |\theta_i g_i|$ 。代表: GaLLeP、SHiRA-SNIP、PST。
5. 学习型 mask / gate 类: s_i 不是解析式, 而是通过训练得到的可学习变量。代表: Masking、Diff Pruning。
6. 动态 drop-grow 类: $s_i^{\text{drop}} = -|\phi_i - \phi_{0,i}|$, $s_i^{\text{grow}} = |\hat{g}_i|$ 或 $|\hat{m}_i|$ 。代表: SpIEL。
7. 访问频次 / 稀有性类: $s_i = \text{TF}(i) \text{IDF}(i)$ 。代表: Sparse Memory Finetuning。
8. 激活驱动类: $s_c = \|A_{:,c}\|_2$ 或 $s_c = q_c k_c$ 。代表: SparseLoRA。

6 对当前研究方向最相关的观察

如果目标是把依赖全量梯度的 sparse selective 指标改造成 online / sampling 可估计版本, 那么最值得盯住的是下面这些原型:

1. $|g_i|$: SIFT、SAFT、SMT、SHiRA-Grad;
2. g_i^2 : Child-Tuning-D、SPT、FISH-DIP;
3. $|g_i|/(|\theta_i| + \varepsilon)$: GaLLeP;
4. movement / diff: LT-SFT、Diff Pruning;
5. 访问统计 / activation 统计: Sparse Memory Finetuning、SparseLoRA。

其中第 1、2、3 类最直接依赖稠密梯度; 第 4 类依赖“全量训练后差值”或学习到的门控; 第 5 类最像把“重要性”改写成访问频次或激活强度, 因此最接近不显式依赖全量梯度的路线。

7 可能可取的候选指标

下面这些不是论文原式, 而是基于上述文献整理出的候选指标。

本节统一记号与严格定义。 本节只使用这一组局部记号; 若与全文前面的统一记号重复, 则含义完全相同。

- 在线打分步: $t = 1, 2, \dots$ 。第 t 步表示进行一次“用当前小批量估计重要性并更新分数”的时刻。
- 第 t 步的小批量: $\mathcal{B}_t = \{(x_{t,b}, y_{t,b})\}_{b=1}^{B_t} \subseteq \mathcal{D}$, 其中 $B_t = |\mathcal{B}_t|$ 。
- 第 t 步参数: $\theta^{(t)} \in \mathbb{R}^D$; 初始预训练参数: $\theta^{(0)} \in \mathbb{R}^D$ 。

- 第 t 步经验损失:

$$\mathcal{L}_{\mathcal{B}_t}(\theta^{(t)}) = \frac{1}{B_t} \sum_{b=1}^{B_t} \ell(x_{t,b}, y_{t,b}; \theta^{(t)}).$$

- 第 t 步参数梯度:

$$g_t := \nabla_{\theta} \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)}) \in \mathbb{R}^D, \quad g_{t,i} := \frac{\partial \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)})}{\partial \theta_i}.$$

- 第 t 步重要性分数向量: $s^{(t)} \in \mathbb{R}^D$; 其第 i 维记为 $s_i^{(t)}$ 。若按矩阵元素打分, 则记为 $s_{uv}^{(t)}$ 。
- 稀疏支持大小: $K \in \{1, \dots, D\}$ 。对应的二值选择掩码定义为

$$m_i^{(t)} := \mathbf{1}[i \in \text{TopK}(s^{(t)}, K)].$$

- 指数滑动平均平滑系数: $\beta \in [0, 1)$ 。对任意标量序列 $z^{(t)}$, 定义

$$\text{EMA}_{\beta}(z)^{(t)} := \beta \text{EMA}_{\beta}(z)^{(t-1)} + (1 - \beta)z^{(t)}, \quad \text{EMA}_{\beta}(z)^{(0)} := 0.$$

- 数值稳定常数: $\varepsilon > 0$ 。
- 若在某一层矩阵参数上定义指标, 则记该层权重为 $W \in \mathbb{R}^{H_{\text{out}} \times H_{\text{in}}}$, 第 t 步的矩阵梯度为

$$G_t := \nabla_W \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)}) \in \mathbb{R}^{H_{\text{out}} \times H_{\text{in}}}, \quad G_{t,uv} := \frac{\partial \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)})}{\partial W_{uv}}.$$

- 若该层在第 t 步共处理 M_t 个 token / 位置, 则输入激活矩阵记为 $X_t = (x_{t,m,v}) \in \mathbb{R}^{M_t \times H_{\text{in}}}$ 。记该层线性变换的 pre-activation 为 $Z_t = (z_{t,m,u}) \in \mathbb{R}^{M_t \times H_{\text{out}}}$, 其中

$$z_{t,m,u} := \sum_{v=1}^{H_{\text{in}}} W_{uv} x_{t,m,v}.$$

上游反向信号矩阵记为 $R_t = (r_{t,m,u}) \in \mathbb{R}^{M_t \times H_{\text{out}}}$, 并严格定义为

$$r_{t,m,u} := \frac{\partial \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)})}{\partial z_{t,m,u}}.$$

线性层梯度满足

$$G_{t,uv} = \frac{1}{M_t} \sum_{m=1}^{M_t} r_{t,m,u} x_{t,m,v}.$$

- 触发统计量: $h_{t,m,i} \geq 0$ 表示第 t 步第 m 个局部事件对第 i 个参数或通道给出的可观测触发强度; 它可以取单样本梯度绝对值、激活绝对值、是否被采样命中等。对应阈值记为 $\kappa > 0$ 。
- 文档频次计数: $n_i^{(t)} := \sum_{\tau=1}^t \mathbf{1}[c_i^{(\tau)} > 0]$, 其中 $c_i^{(\tau)}$ 是第 τ 步内第 i 个位置的触发次数。
- movement: $\Delta_i^{(t)} := \theta_i^{(t)} - \theta_i^{(0)}$ 。
- 混合系数: $\lambda \in [0, 1]$ 。
- 若把某个“基础分数”序列再做稳定化, 则记该基础分数为 $\tilde{s}^{(t)}$, 其第 i 维为 $\tilde{s}_i^{(t)}$ 。

- 持续入选指标中, $u_i^{(t)} \in \{0, 1\}$ 表示第 t 步是否入选, $p_i^{(t)} \in [0, 1]$ 表示其平滑后的入选频率。
- 本节还会用到若干中间统计量: $v_i^{(t)}$ 表示 $g_{t,i}^2$ 的指数滑动平均, $\mu_i^{(t)}$ 表示 $g_{t,i}$ 的指数滑动平均, $q_i^{(t)}$ 表示 $g_{t,i}^2$ 的指数滑动平均但在信噪比指标中被解释为二阶原始矩, $\sigma_i^{(t)}$ 表示由 $\mu_i^{(t)}$ 与 $q_i^{(t)}$ 导出的标准差估计, $\bar{g}_i^{(t)}$ 表示 $|g_{t,i}|$ 的指数滑动平均, $c_{uv}^{(t)}$ 表示矩阵元素 W_{uv} 的局部激活-反传贡献强度。

在线 Fisher / EMA 梯度平方。 来源原型是 Child-Tuning-D 的 empirical Fisher 对角元, 以及 FISH-DIP、SPT 中与 g_i^2 同型的平方梯度指标。计算时先在第 t 步求出小批量梯度 g_t , 然后对每个参数坐标维护平方梯度的指数滑动平均

$$v_i^{(t)} := \beta v_i^{(t-1)} + (1 - \beta) g_{t,i}^2, \quad v_i^{(0)} := 0.$$

再把当前重要性分数定义为

$$s_i^{(t)} := v_i^{(t)}.$$

如果要在第 t 步立即选 support, 就按 $m_i^{(t)} = \mathbf{1}[i \in \text{TopK}(v^{(t)}, K)]$ 取前 K 个位置。这里 $v_i^{(t)}$ 的由来是“平方梯度近似 Fisher 对角元”, 其计算方法是“每一步只用当前小批量的 $g_{t,i}^2$ 更新一次”, 因此不需要额外跑一次全量梯度。

在线 GaLLeP 比值。 来源原型是 GaLLeP 的“高梯度 + 低预训练模长”筛选思想。仍然先用

$$v_i^{(t)} := \beta v_i^{(t-1)} + (1 - \beta) g_{t,i}^2$$

维护第 i 个参数的在线二阶梯度尺度, 再定义

$$s_i^{(t)} := \frac{\sqrt{v_i^{(t)}}}{|\theta_i^{(0)}| + \varepsilon}.$$

这里分子 $\sqrt{v_i^{(t)}}$ 是第 i 个参数梯度绝对值的平滑估计, 分母 $|\theta_i^{(0)}| + \varepsilon$ 是该参数在预训练初始化时的绝对模长。于是 $s_i^{(t)}$ 大, 当且仅当“当前一直被较大梯度推动, 但初始权重本身并不大”, 这正是 GaLLeP 指标的在线化版本。

梯度信噪比。 来源原型是 SIFT、SAFT、SMT、SHiRA-Grad 这类直接依赖 $|g_i|$ 的梯度幅值指标; 这里进一步要求“梯度不仅大, 而且长期方向稳定”。为此先定义一阶矩、二阶原始矩和标准差:

$$\begin{aligned} \mu_i^{(t)} &:= \beta \mu_i^{(t-1)} + (1 - \beta) g_{t,i}, & \mu_i^{(0)} &:= 0, \\ q_i^{(t)} &:= \beta q_i^{(t-1)} + (1 - \beta) g_{t,i}^2, & q_i^{(0)} &:= 0, \\ \sigma_i^{(t)} &:= \sqrt{\max\left\{q_i^{(t)} - \left(\mu_i^{(t)}\right)^2, 0\right\}}. \end{aligned}$$

最终分数定义为

$$s_i^{(t)} := \frac{|\mu_i^{(t)}|}{\sigma_i^{(t)} + \varepsilon}.$$

其中 $\mu_i^{(t)}$ 衡量平均推动方向， $\sigma_i^{(t)}$ 衡量波动程度，所以 $s_i^{(t)}$ 大意味着“该位置在许多步上持续收到同方向的大梯度”，而不是被少数 noisy batch 偶然抬高。

Activation-weighted gradient. 来源原型是 SparseLoRA 的激活强度打分，以及 SIFT / SAFT / SMT 等工作中的梯度驱动打分。这里把二者结合成一个矩阵元素级指标。

先把这一层的局部前向传播写清楚。对第 t 步的第 m 个 token / 位置，输入向量记为

$$x_{t,m} = (x_{t,m,1}, \dots, x_{t,m,H_{\text{in}}})^\top \in \mathbb{R}^{H_{\text{in}}},$$

线性层参数为 $W \in \mathbb{R}^{H_{\text{out}} \times H_{\text{in}}}$ ，于是该位置在线性层输出的第 u 个 pre-activation 为

$$z_{t,m,u} = \sum_{v=1}^{H_{\text{in}}} W_{uv} x_{t,m,v}.$$

反向传播时，对应的上游信号定义为

$$r_{t,m,u} := \frac{\partial \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)})}{\partial z_{t,m,u}}.$$

也就是说， $r_{t,m,u}$ 不是新的自由记号，而就是“损失对该线性层输出坐标 $z_{t,m,u}$ 的偏导数”。是由链式法则，

$$\frac{\partial \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)})}{\partial W_{uv}} = \sum_{m=1}^{M_t} \frac{\partial \mathcal{L}_{\mathcal{B}_t}(\theta^{(t)})}{\partial z_{t,m,u}} \frac{\partial z_{t,m,u}}{\partial W_{uv}} = \sum_{m=1}^{M_t} r_{t,m,u} x_{t,m,v}.$$

若把损失写成对 M_t 个位置的平均，则对应平均梯度就是

$$G_{t,uv} = \frac{1}{M_t} \sum_{m=1}^{M_t} r_{t,m,u} x_{t,m,v}.$$

这说明矩阵元素 W_{uv} 在第 t 步的梯度，本质上就是各位置局部乘积 $r_{t,m,u} x_{t,m,v}$ 的平均。

因此，对矩阵元素 W_{uv} ，定义其第 t 步的局部贡献强度为

$$c_{uv}^{(t)} := \frac{1}{M_t} \sum_{m=1}^{M_t} |r_{t,m,u} x_{t,m,v}|.$$

再把在线重要性分数定义为

$$s_{uv}^{(t)} := \beta s_{uv}^{(t-1)} + (1 - \beta) c_{uv}^{(t)}, \quad s_{uv}^{(0)} := 0.$$

这里和普通梯度的差别在于：普通梯度先把 $\sum_m r_{t,m,u} x_{t,m,v}$ 做带符号求和，不同位置的正负贡献可能互相抵消；而 $c_{uv}^{(t)}$ 先取绝对值再平均，所以它更像“这个参数在当前 batch 中一共被多强地使用和驱动过”。把 $c_{uv}^{(t)}$ 再做时间平滑，就得到“同时看激活是否强、反向信号是否强”的 online 指标。

若你要真正实现这个指标，那么每一步只需要这 4 类信息：

1. 目标层输入激活 $x_{t,m,v}$: 也就是该线性层 forward 时喂进去的输入;
2. 目标层输出的反向信号 $r_{t,m,u} = \partial \mathcal{L}_{B_t}(\theta^{(t)}) / \partial z_{t,m,u}$: 也就是 backward 经过该层时, 损失对该层 pre-activation 的梯度;
3. 参数索引 (u, v) 与实际可训练单元之间的对应关系: 如果你筛的是单个参数, 就直接用 (u, v) ; 如果你筛的是整行、整列、整通道或 block, 就把对应元素的 $c_{uv}^{(t)}$ 再聚合;
4. 一个时间平滑状态 $s_{uv}^{(t-1)}$: 用来做 EMA 更新。

最直接的实现流程是:

1. 在第 t 步 forward 时, 缓存目标层输入 X_t ;
2. 在第 t 步 backward 时, 读取该层 pre-activation 的梯度 R_t ;
3. 对每个候选参数 W_{uv} 计算

$$c_{uv}^{(t)} = \frac{1}{M_t} \sum_{m=1}^{M_t} |r_{t,m,u} x_{t,m,v}|;$$

4. 用

$$s_{uv}^{(t)} = \beta s_{uv}^{(t-1)} + (1 - \beta) c_{uv}^{(t)}$$

更新在线分数;

5. 若要做 sparse selective, 就按 $s_{uv}^{(t)}$ 或其聚合版本取 TopK。

若要回到向量参数记号, 只需把二重索引 (u, v) 展平成单索引 i 。若你不想显式形成整张梯度矩阵 G_t , 也可以直接从缓存的 X_t 和反向信号 R_t 计算 $c_{uv}^{(t)}$ 或其抽样估计。

参数版 TF-IDF。 来源原型是 Sparse Memory Finetuning 用访问统计量构造记忆重要性的 TF-IDF 机制。这里把“词项出现”改写成“参数或通道被触发”。先选定一个局部触发统计量 $h_{t,m,i} \geq 0$, 例如单样本梯度绝对值、通道激活绝对值或采样命中指标, 并设阈值 $\kappa > 0$ 。第 t 步内第 i 个位置的触发次数定义为

$$c_i^{(t)} := \sum_{m=1}^{M_t} \mathbf{1}[h_{t,m,i} > \kappa].$$

于是第 t 步的 term frequency 定义为

$$\text{tf}_i^{(t)} := \frac{c_i^{(t)}}{\sum_{j=1}^D c_j^{(t)} + \varepsilon},$$

到第 t 步为止的 document frequency 定义为

$$n_i^{(t)} := \sum_{\tau=1}^t \mathbf{1}[c_i^{(\tau)} > 0],$$

对应的 inverse document frequency 为

$$\text{idf}_i^{(t)} := \log \frac{t + 1}{n_i^{(t)} + 1}.$$

最终分数定义为

$$s_i^{(t)} := \text{tf}_i^{(t)} \text{idf}_i^{(t)}.$$

于是 $s_i^{(t)}$ 大表示第 i 个位置“在当前 batch 里被频繁触发，但从长期历史看并不是所有 batch 都会触发”，也就是同时具备局部高频和全局区分性。

Movement + recency. 来源原型是 LT-SFT / Diff Pruning 的 movement 指标，以及 SIFT / SAFT 这类基于 $|g_i|$ 的即刻梯度指标。这里把“累计位移”和“最近仍然活跃”合并到一个分数中。先定义

$$\Delta_i^{(t)} := \theta_i^{(t)} - \theta_i^{(0)},$$

以及梯度绝对值的指数滑动平均

$$\bar{g}_i^{(t)} := \beta \bar{g}_i^{(t-1)} + (1 - \beta) |g_{t,i}|, \quad \bar{g}_i^{(0)} := 0.$$

然后定义混合分数

$$s_i^{(t)} := \lambda |\Delta_i^{(t)}| + (1 - \lambda) \bar{g}_i^{(t)}.$$

这里 $|\Delta_i^{(t)}|$ 衡量“到目前为止这个参数累计偏离初始化有多远”， $\bar{g}_i^{(t)}$ 衡量“最近这些步它是否仍被持续推动”，所以该指标偏好既在长期上发生过实质变化、又在当前阶段依然活跃的位置。

持续入选频率。 来源原型不是某一篇文章的原式，而是对任何 TopK 型 sparse selective 规则都可叠加的一层时间稳定化。设 $\tilde{s}^{(t)}$ 是某个基础候选指标在第 t 步产生的分数，例如上面的在线 Fisher 或在线 GaLLOP。先定义瞬时入选指示变量

$$u_i^{(t)} := \mathbf{1}[i \in \text{TopK}(\tilde{s}^{(t)}, K)].$$

再定义其时间平滑频率

$$p_i^{(t)} := \beta p_i^{(t-1)} + (1 - \beta) u_i^{(t)}, \quad p_i^{(0)} := 0.$$

最后真正用于输出 support 的不是 $\tilde{s}^{(t)}$ ，而是

$$m_i^{(t)} := \mathbf{1}[i \in \text{TopK}(p^{(t)}, K)].$$

这里 $u_i^{(t)}$ 的计算方法是“看第 t 步是否入选基础 TopK”， $p_i^{(t)}$ 的计算方法是“对这个 0-1 入选事件做指数滑动平均”，所以它衡量的是“一个位置是否长期反复被判为重要”，而不是某一步偶然冲高。

8 结论

如果只看这个文件夹里的 sparse PEFT 文献，那么它们背后的重要性原型基本可以压缩成 6 类：绝对梯度、平方梯度 / Fisher、movement、梯度与预训练模长的比值、访问频次 / TF-IDF、激活统计。若目标是把“先算一次全量梯度再筛 support”的流程改成 online / sampling 可估计的流程，那么在本节统一记号下，我认为最值得优先实验的 5 类候选指标依次是：

1. 在线 Fisher: $s_i^{(t)} = v_i^{(t)}$, 其中 $v_i^{(t)} = \beta v_i^{(t-1)} + (1-\beta)g_{t,i}^2$ 。这是对 Child-Tuning-D、FISH-DIP、SPT 原型最直接的 online 化。
2. 在线 GaLLOP 比值: $s_i^{(t)} = \sqrt{v_i^{(t)}} / (|\theta_i^{(0)}| + \varepsilon)$ 。它保留了 GaLLOP 的“高梯度 + 低初始模长”偏好, 但把全量梯度改成逐步估计。
3. Activation-weighted gradient: $s_{uv}^{(t)} = \beta s_{uv}^{(t-1)} + (1-\beta)c_{uv}^{(t)}$, 其中 $c_{uv}^{(t)} = \frac{1}{M_t} \sum_{m=1}^{M_t} |r_{t,m,u} x_{t,m,v}|$ 。它同时利用前向激活和反向信号, 不必显式额外计算一次稠密筛选梯度。
4. 参数版 TF-IDF: $s_i^{(t)} = \text{tf}_i^{(t)} \text{idf}_i^{(t)}$, 其中 $\text{tf}_i^{(t)}$ 来自当前触发次数 $c_i^{(t)}$, $\text{idf}_i^{(t)}$ 来自历史触发步数 $n_i^{(t)}$ 。它完全可以建立在访问统计或触发统计上, 而不依赖全量梯度。
5. Movement + recency: $s_i^{(t)} = \lambda |\Delta_i^{(t)}| + (1-\lambda)\bar{g}_i^{(t)}$ 。它把 LT-SFT / Diff Pruning 的长期位移和梯度法的近期活跃度合在一起。

这 5 类里, 前两类与现有 sparse selective 文献最同构, 第三类最容易把 SparseLoRA 式 activation insight 融合进来, 第四类最接近“完全摆脱梯度筛选”的路线, 第五类则最适合把历史变化信息并入在线打分。共同点是: 它们都能在每一步只利用当前 batch 的局部可观测量递推更新, 而不需要单独进行一次全量梯度扫描。

9 供当前研究直接使用的指标写法

这一节不是文献总结, 而是把当前研究里真正会用到的指标, 按全文记号重写成可直接引用的形式。

为什么这里只考虑一阶和二阶导数。在参数重要性评估阶段, 通常先固定一个参考参数点, 再问“若只允许很小的局部更新, 哪些位置最值得保留”。这时对单样本损失 $\ell(x, y; \theta)$ 在参考点附近作二阶展开:

$$\ell(x, y; \bar{\theta} + \Delta) \approx \ell(x, y; \bar{\theta}) + \nabla_{\theta} \ell(x, y; \bar{\theta})^{\top} \Delta + \frac{1}{2} \Delta^{\top} H(x, y; \bar{\theta}) \Delta.$$

其中一阶导数决定局部下降方向和线性收益, 二阶导数决定局部曲率、步长缩放与参数耦合。若目标只是做局部重要性排序, 那么一阶与二阶信息已经覆盖了“往哪走”和“能走多远”这两个核心问题; 更高阶导数一方面计算代价显著更高, 另一方面只有在更新步长不再局部时才会稳定改变排序。因此这一节只保留一阶与二阶量。

本节统一记号与严格定义。 本节额外固定一个参考参数向量

$$\bar{\theta} \in \mathbb{R}^D,$$

它表示进行重要性评估时被冻结不动的参数点。样本随机性只来自独立抽样: 设

$$Z = (X, Y) \sim \mathbb{P},$$

其中 $\mathbb{P}$ 表示数据分布，或等价地表示从有限数据集 $\mathcal{D}$ 上均匀抽样得到的经验分布。对任意参数位置 $i \in \{1, \dots, D\}$ ，定义该位置在单样本上的梯度随机变量

$$g_i(Z; \bar{\theta}) := \frac{\partial \ell(X, Y; \bar{\theta})}{\partial \theta_i}.$$

若采用预训练初值做归一化，则该位置的参考参数模长记为 $|\theta_i^{(0)}|$ ；若实际想用当前冻结点 $\bar{\theta}_i$ 做归一化，只需把下文中的 $|\theta_i^{(0)}|$ 全部替换为 $|\bar{\theta}_i|$ 。

进一步定义该位置的一阶、绝对一阶和二阶矩

$$\begin{aligned} \mu_i &:= \mathbb{E}[g_i(Z; \bar{\theta})], & a_i &:= \mathbb{E}[|g_i(Z; \bar{\theta})|], \\ v_i &:= \mathbb{E}[g_i(Z; \bar{\theta})^2], & \sigma_i &:= \sqrt{v_i - \mu_i^2}. \end{aligned}$$

其中 μ_i 表示平均梯度， a_i 表示平均绝对梯度， v_i 表示二阶矩， σ_i 表示梯度波动的标准差。

单位位置的重要性指标。 在上述定义下，对位置 i 可直接考虑以下 7 个标量分数：

$$\begin{aligned} S_i^{(1)} &:= \mathbb{E}[|g_i(Z; \bar{\theta})|] = a_i, \\ S_i^{(2)} &:= |\mathbb{E}[g_i(Z; \bar{\theta})]| = |\mu_i|, \\ S_i^{(3)} &:= \mathbb{E}[g_i(Z; \bar{\theta})^2] = v_i, \\ S_i^{(4)} &:= \frac{\sqrt{\mathbb{E}[g_i(Z; \bar{\theta})^2]}}{|\theta_i^{(0)}| + \varepsilon} = \frac{\sqrt{v_i}}{|\theta_i^{(0)}| + \varepsilon}, \\ S_i^{(5)} &:= \frac{|\mathbb{E}[g_i(Z; \bar{\theta})]|}{|\theta_i^{(0)}| + \varepsilon} = \frac{|\mu_i|}{|\theta_i^{(0)}| + \varepsilon}, \\ S_i^{(6)} &:= \frac{|\mathbb{E}[g_i(Z; \bar{\theta})]|}{\sqrt{\mathbb{E}[g_i(Z; \bar{\theta})^2] - (\mathbb{E}[g_i(Z; \bar{\theta})])^2} + \varepsilon} = \frac{|\mu_i|}{\sigma_i + \varepsilon}, \\ S_i^{(7)} &:= \frac{|\mathbb{E}[g_i(Z; \bar{\theta})]|}{\mathbb{E}[g_i(Z; \bar{\theta})^2] + \varepsilon} = \frac{|\mu_i|}{v_i + \varepsilon}. \end{aligned}$$

它们的含义分别是：

1. $S_i^{(1)}$ 衡量该位置平均会收到多大的梯度幅值，不要求方向一致；
2. $S_i^{(2)}$ 衡量该位置是否长期存在稳定的净推动方向；
3. $S_i^{(3)}$ 衡量该位置的二阶能量，与 Fisher 对角近似最接近；
4. $S_i^{(4)}$ 与 $S_i^{(5)}$ 进一步用参数模长归一化，偏好“梯度信号强但参数本身不大”的位置；
5. $S_i^{(6)}$ 是信噪比型指标，偏好“平均推动大且波动小”的位置；
6. $S_i^{(7)}$ 用二阶曲率近似 Newton 分母，更接近对角 Newton 步长。

单位置指标的样本平均估计。现在假设在固定参数点 $\bar{\theta}$ 上独立抽到 n 个样本

$$Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}.$$

对位置 i , 记

$$g_{i,b} := g_i(Z_b; \bar{\theta}) = \frac{\partial \ell(X_b, Y_b; \bar{\theta})}{\partial \theta_i}, \quad b = 1, \dots, n.$$

则各个总体矩的自然估计就是直接样本平均:

$$\begin{aligned} \hat{\mu}_{i,n} &:= \frac{1}{n} \sum_{b=1}^n g_{i,b}, & \hat{a}_{i,n} &:= \frac{1}{n} \sum_{b=1}^n |g_{i,b}|, \\ \hat{v}_{i,n} &:= \frac{1}{n} \sum_{b=1}^n g_{i,b}^2, & \hat{\sigma}_{i,n} &:= \sqrt{\max\{\hat{v}_{i,n} - \hat{\mu}_{i,n}^2, 0\}}. \end{aligned}$$

于是对应的样本版分数定义为

$$\begin{aligned} \hat{S}_{i,n}^{(1)} &:= \hat{a}_{i,n}, & \hat{S}_{i,n}^{(2)} &:= |\hat{\mu}_{i,n}|, & \hat{S}_{i,n}^{(3)} &:= \hat{v}_{i,n}, \\ \hat{S}_{i,n}^{(4)} &:= \frac{\sqrt{\hat{v}_{i,n}}}{|\theta_i^{(0)}| + \varepsilon}, & \hat{S}_{i,n}^{(5)} &:= \frac{|\hat{\mu}_{i,n}|}{|\theta_i^{(0)}| + \varepsilon}, \\ \hat{S}_{i,n}^{(6)} &:= \frac{|\hat{\mu}_{i,n}|}{\hat{\sigma}_{i,n} + \varepsilon}, & \hat{S}_{i,n}^{(7)} &:= \frac{|\hat{\mu}_{i,n}|}{\hat{v}_{i,n} + \varepsilon}. \end{aligned}$$

这些估计可以按顺序累加分子与分母所需的和, 但最终形式应始终与“直接把 n 个独立样本求平均”完全一致。

多位置情形下的 Fisher / Newton 指标。 若不只看单个位置, 而是同时在一个候选集里做筛选, 为避免与前文的 TopK 保留数 K 混淆, 这里把候选集大小记为 M 。设候选集为

$$\mathcal{I} = \{i_1, \dots, i_M\} \subseteq \{1, \dots, D\}.$$

对单个随机样本 Z , 定义该候选集上的梯度向量

$$u(Z; \bar{\theta}) := \begin{bmatrix} g_{i_1}(Z; \bar{\theta}) \\ \vdots \\ g_{i_M}(Z; \bar{\theta}) \end{bmatrix} \in \mathbb{R}^M.$$

这个向量对应于你口头描述里的 s , 这里只是为了不与全文中的“分数向量” s 冲突, 改记为 u 。进一步定义平均梯度向量与 Fisher 信息矩阵

$$\begin{aligned} \mu_{\mathcal{I}} &:= \mathbb{E}[u(Z; \bar{\theta})] \in \mathbb{R}^M, \\ F_{\mathcal{I}} &:= \mathbb{E}[u(Z; \bar{\theta})u(Z; \bar{\theta})^\top] \in \mathbb{R}^{M \times M}. \end{aligned}$$

若用 Fisher 近似局部二阶信息, 则正则化 Newton 方向定义为

$$r_{\mathcal{I}}^* := (F_{\mathcal{I}} + \lambda I)^{-1} \mu_{\mathcal{I}}.$$

其中第 j 个坐标衡量: 在把候选位置之间的二阶耦合也考虑进去后, 位置 i_j 的有效 Newton 方向有多大。

多位置指标的样本平均估计。 给定 n 个独立样本 $Z_1, \dots, Z_n$, 定义

$$u_b := u(Z_b; \bar{\theta}) \in \mathbb{R}^M, \quad b = 1, \dots, n.$$

则平均梯度和 Fisher 的自然经验估计为

$$\hat{\mu}_{\mathcal{I},n} := \frac{1}{n} \sum_{b=1}^n u_b, \quad \hat{F}_{\mathcal{I},n} := \frac{1}{n} \sum_{b=1}^n u_b u_b^\top.$$

相应的经验 Newton 向量定义为

$$\hat{r}_{\mathcal{I},n} := \left(\hat{F}_{\mathcal{I},n} + \lambda I \right)^{-1} \hat{\mu}_{\mathcal{I},n}.$$

若最终只需要排序, 则可对第 j 个候选位置定义分数

$$\hat{q}_{j,n} := |(\hat{r}_{\mathcal{I},n})_j|, \quad j = 1, \dots, M.$$

逆 Fisher 的递推估计。 若不想在每次新增样本后重新求逆, 则可定义

$$A_n := \lambda I + \sum_{b=1}^n u_b u_b^\top, \quad C_n := A_n^{-1}.$$

当加入第 $n+1$ 个样本 u_{n+1} 时, Sherman–Morrison 递推给出

$$C_{n+1} = C_n - \frac{C_n u_{n+1} u_{n+1}^\top C_n}{1 + u_{n+1}^\top C_n u_{n+1}}, \quad C_0 = \lambda^{-1} I.$$

这个递推严格对应的是

$$C_n = \left(\lambda I + \sum_{b=1}^n u_b u_b^\top \right)^{-1}.$$

又因为

$$\lambda I + \sum_{b=1}^n u_b u_b^\top = n \left(\hat{F}_{\mathcal{I},n} + \frac{\lambda}{n} I \right),$$

所以

$$C_n \hat{\mu}_{\mathcal{I},n} = \frac{1}{n} \left(\hat{F}_{\mathcal{I},n} + \frac{\lambda}{n} I \right)^{-1} \hat{\mu}_{\mathcal{I},n}.$$

因此, 若你的最终目标只是对候选位置排序, 那么直接使用

$$\tilde{q}_{j,n} := |(C_n \hat{\mu}_{\mathcal{I},n})_j|$$

与使用右边那个经验 Newton 向量做排序是等价的, 因为二者只差一个与坐标无关的正比例因子 $1/n$ 。若你更关心 Newton 向量的绝对量级而非纯排序, 则应显式补回这个缩放关系。

这一节内部各指标的关系。从便宜到昂贵、从对角到全耦合，这一节的指标大致形成如下层级：

1. $\hat{S}_{i,n}^{(1)}$ 、 $\hat{S}_{i,n}^{(2)}$ 、 $\hat{S}_{i,n}^{(3)}$ 只用单位置的一阶与二阶矩；
2. $\hat{S}_{i,n}^{(4)}$ 、 $\hat{S}_{i,n}^{(5)}$ 再引入参数模长归一化；
3. $\hat{S}_{i,n}^{(6)}$ 进一步利用方差信息，强调稳定性；
4. $\hat{S}_{i,n}^{(7)}$ 用对角 Fisher 近似一维 Newton 步长；
5. $\hat{r}_{\mathcal{I},n}$ 或 $C_n\hat{\mu}_{\mathcal{I},n}$ 则把候选位置之间的相关性也纳入，属于矩阵版 Newton / inverse-Fisher 选择。

若只想先做稳定、廉价、易实现的实验，通常从 $\hat{S}_{i,n}^{(3)}$ 、 $\hat{S}_{i,n}^{(5)}$ 、 $\hat{S}_{i,n}^{(6)}$ 开始最自然；若明确希望利用候选位置之间的耦合结构，再上升到 $\hat{r}_{\mathcal{I},n}$ 或 $C_n\hat{\mu}_{\mathcal{I},n}$ 这一层。